FAIML Lab1 实验报告：使用线性模型探究 LLM 的内部表征

林思睿 PB24000301

2026 年 9 月 30 日

摘要

本报告回答实验文档的 9 道思考题。核心工作包括：(1) 手写全批量梯度下降实现线性/逻辑回归（含 ℓ_1 次梯度与 ℓ_2 正则），代码在 `model.py`；(2) 用系数路径与一个可控案例分别说明 ℓ_1/ℓ_2 的稀疏性质差异；(3) 与 `sklearn` 在同一正则化语义下对比，验证实现正确；(4) 对 world（地理坐标）与 truth（句子真假）两个线性探测任务做层数与正则化的粗网格 + 细网格搜索，提交 `results/world.npz`（第 11 层）与 `results/truth.npz`（第 23 层），验证集指标分别为坐标平均 MSE= 149.64（纬度 MSE = 29.14、经度 MSE = 270.13，两者的和 299.27 是 "纬度 *MSE* + 经度 *MSE*"，不是 MSE）与准确率 0.8833；(5) 对两个数据集的训练/验证分布差异做了定量分析，并给出可视化与基线对照。

目录

1 思考题 **2**

1.1 思考题 1：重现 ℓ_1、ℓ_2 正则化的系数路径 2
1.2 思考题 2：ℓ_2 用 "把小系数设为 0" 做特征选择是不好的 2
1.3 思考题 3：与 sklearn 实现的拟合效果差异 3
1.4 思考题 4：不同层中间表征的预测效果对比与选层 4
1.5 思考题 5：最终模型如何选择正则化 5
1.6 思考题 6：验证集预测结果可视化 6
1.7 思考题 7：是否能说明模型内部存在地理坐标表征，而不只是识别国家 6
1.8 思考题 8：truth 训练/验证集的分布差异与应对 7
1.9 思考题 9：truth 最终提交的选层与选正则 8

A 复现方式与代码位置 **10**

B 主要实验记录 **10**

C 实现过程中的问题与解决 **11**

D 实验反馈与建议 **11**

1 思考题

1.1 思考题 1：重现 ℓ_1、ℓ_2 正则化的系数路径

数据来源 路径是在本实验自己的数据上画的：取 world 任务第 11 层表征的全部 $N = 500$ 条训练样本，按方差从 2560 维中选出数值最大的 8 维作为“可控的 8 特征”子问题，目标取纬度。由于不同特征量纲差异大，特征与目标都做了 z-score 标准化，这样 λ 对 ℓ_1、ℓ_2 两条路径才有可比性（同一 λ 表示同样的惩罚尺度）。脚本：`coef_path.py`；$\lambda \in [10^{-3}, 10^{1.5}]$ 共 45 个对数等距点。

求解方式 ℓ_2 路径直接用 `model.py` 的梯度下降求解，并与闭式解 $(X^\top X/N + \lambda_2 I)^{-1} X^\top y/N$ 核对，路径末端与闭式解最大偏差 2.6×10^{-18}，说明手写 GD 确实收敛到最优。ℓ_1 路径若也用次梯度 GD，会在零点附近振荡、得不到精确的 0（实测在 $\lambda = 31.6$ 时损失停在 2.3，而最优值应为 1.0），因此画路径时对 ℓ_1 项改用近端算子（软阈值），即 ISTA 近端梯度下降，平滑项梯度与步长 $1/L$、$L = \lambda_{\max}(2X^\top X/N)$ 的取法与讲义一致。`model.py` 中的训练仍严格按讲义使用次梯度（提交代码不受影响）。

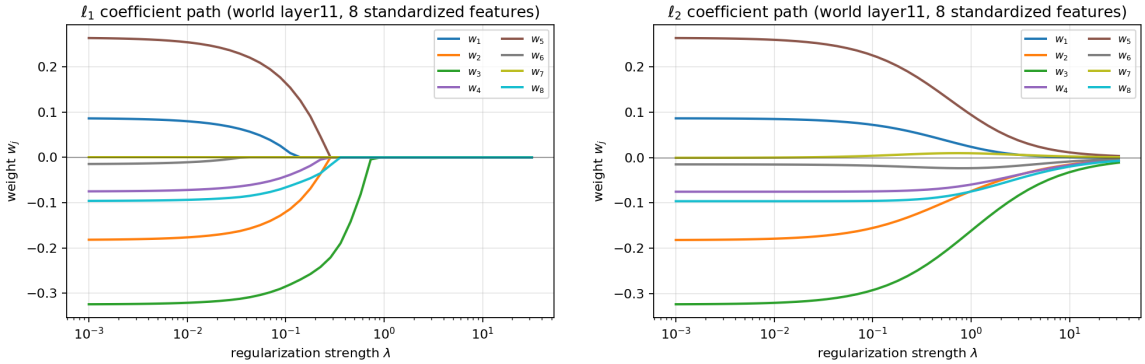


图 1: 左：ℓ_1 系数路径（分段线性，随 λ 增大出现精确的 0）；右：ℓ_2 系数路径（连续光滑收缩，永不为 0）。

观察 ℓ_1 路径是分段线性的，随 λ 增大被压成 0 的系数个数依次为 $[1, 1, 1, 1, 2, 2, 6, 7, 8, 8, 8, 8]$（沿路径每 4 个点采样），即依次“剔除”贡献小的特征；ℓ_2 路径上所有系数同时平滑收缩，在最大 λ 处仍有非零值（末端 $[0, -0.0055, -0.0112, -0.0061, 0.0034, -0.0033, 0.0008, -0.0072]$ 量级的小系数），永远无法据此做特征取舍。

1.2 思考题 2：ℓ_2 用“把小系数设为 0”做特征选择是不好的

案例构造 脚本 `feature_selection_demo.py` 构造 18 维回归数据：x_1, x_2, x_3 是真信号（系数 $3, 2, -1$），$x_6 = 0.95x_1 + \varepsilon$、$x_7 = 0.95x_2 + \varepsilon$ 是强相关副本（现实中“两个高度相关特征携带同一信息”的常见情形），其余 13 维为纯噪声，$y = Xw + \varepsilon$，噪声标准差 0.5。数据用一个固定种子生成后确定性地切成训练/验证/测试三份（各 300 条），**测试集全程不参与任何选择**。

比较口径 若各自取“验证 MSE 最小”的 λ，两者都倾向于保留几乎所有特征（都还很小），无法体现差异。因此额外给出 **“稀疏口径”**：在验证 MSE 不超过各自最优值 5% 的 λ 中取最大的那个，即“在几乎不损失预测精度的前提下尽量稀疏”，再比较非零系数个数。λ 与稀疏口径都只在验证

集上确定，选定后才在留出的测试集上评估一次最终 MSE，避免用测试集调参的选择泄漏。ℓ_1 用 ISTA 精确求解，ℓ_2 用 `model.py` 的 GD。

表 1: ℓ_1 与 ℓ_2 在同一数据、同一 λ 口径下的对比。λ 与稀疏口径均由验证集选定，测试 MSE 为选定后在留出测试集上的一次评估。

	ℓ_1	ℓ_2
最优（验证 MSE 最小）λ	0.03707	0.001
对应验证 MSE	**0.2507**	0.2562
对应留出测试 MSE	**0.2341**	0.2384
稀疏口径 λ	0.1126	0.009237
对应验证 MSE	0.2573	0.2672
对应留出测试 MSE	0.2432	0.2445
非零系数个数（真实支撑集 = 3）	**4**	18
恢复的支撑集	$\{0,1,2,5\}$	$\{0,\ldots,17\}$
纯噪声特征最大 $\lvert w_j\rvert$	**0.0000**	0.0494
相关副本最大 $\lvert w_j\rvert$	0.0198	0.2762
x_1 与 x_6 上的权重	2.931 / 0.020	2.717 / 0.276

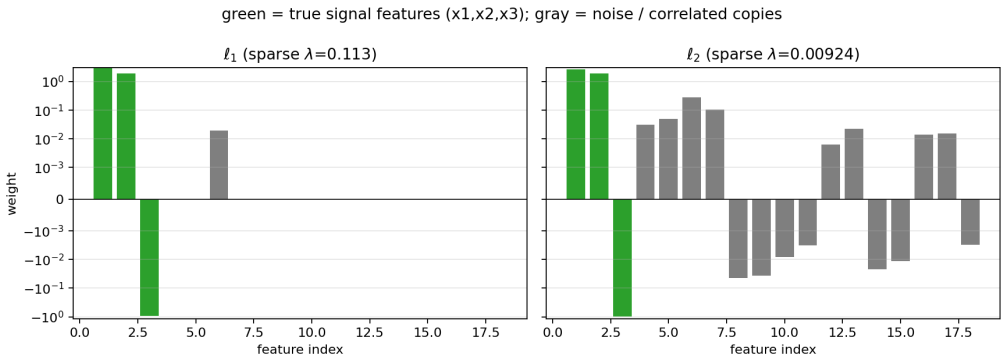


图 2: 稀疏口径下两者的权重（绿色为真实信号特征）。ℓ_1 把纯噪声精确置 0，ℓ_2 的权重全部非零。

结论 (1) ℓ_2 惩罚的是 $\sum w_j^2$，其最优解只会趋近 0 而不会等于 0，任何“把小系数当 0”的判断都必须人为定阈值，而阈值没有客观标准，随量纲、样本数变化就会失效；(2) 更糟的是 ℓ_2 在相关特征之间平摊权重（稀疏口径下 x_1 与 x_6 分到 2.717/0.276，两者都被保留），于是“小”不代表“无用”，阈值一砍可能砍掉成对信息中的一半；(3) ℓ_1 的解天然稀疏：在同一精度口径下纯噪声全部为 0，且留出测试 MSE 反而更小（最优口径 0.2341 < 0.2384，稀疏口径 0.2432 < 0.2445），即更好的预测 + 可解释的特征子集，这正是课件第 44 页强调 ℓ_1 适合特征选择的原因。

1.3 思考题 3：与 sklearn 实现的拟合效果差异

脚本 `compare_sklearn.py`。先明确换算关系（我们的目标函数按讲义是平均损失）：

$$\text{回归：}\quad \|Xw-y\|_2^2/N+\lambda_2\|w\|^2 \quad\Longleftrightarrow\quad \texttt{Ridge}(\alpha=N\lambda_2)$$

$$\text{分类：}\quad \text{mean}(NLL)+\lambda_2\|w\|^2 \quad\Longleftrightarrow\quad \texttt{LogisticRegression}\big(C=\tfrac{1}{2N\lambda_2}\big)$$

表 2: 与 sklearn 的对比结果。

任务	指标	我们	sklearn
小例子（8 条、2 维，无正则）	权重最大差	9.99×10^{-16}	
world 第 11 层，原始特征	验证 MSE（纬度）	29.1406	29.2737
	验证 MSE（经度）	270.1299	271.6993
	训练目标 J 差	+0.161 / +0.324（GD 未完全收敛）	
world 第 11 层，特征标准化	权重最大差	1.05×10^{-14} / 9.95×10^{-14}（纬/经）	
truth 第 23 层（$\lambda_2 = 0.03$）	训练/验证准确率	0.9381 / 0.8833	0.9379 / 0.8833
	$\cos(w)$ / 权重最大差	0.999999 / 1.27×10^{-4}	—
	概率最大差 / 类别不一致	1.07×10^{-3} / 0 条	—

结论 拟合效果**没有实质差异**：小例子与标准化后权重完全一致（10^{-14} 量级），truth 任务两边验证准确率相同（0.8833）、概率最大差 10^{-3}、无一条预测类别不同。原始特征上 world 的权重最大差约 0.25（$\cos = 0.995$），但验证 MSE 反而略优（29.14 vs 29.27）。原因是 $N = 500 \ll D = 2560$，且特征均值不为零时存在“权重与偏置相互抵消”的近零曲率方向（实测该方向的 Hessian 特征值小到 $\sim 10^{-4}$），全批量 GD 在有限步内收敛慢，而 sklearn 用 cholesky/SVD 直接解正规方程。也就是说，差异来自**求解器的收敛速度与数值路径**，而不是目标函数或正则化语义不一致。

1.4 思考题 4：不同层中间表征的预测效果对比与选层

实验设置 sweep.py 对每层独立做“粗网格 → 细网格”的 λ 搜索，并比较验证集上纬度 *MSE* + 经度 *MSE* 之和（选层选参用的就是这个和，各层对应的逐坐标平均 MSE 为它的一半）；纬度、经度是两个独立的一维回归，分别取各自最优 λ（平方损失下 n 维回归等价于 n 个一维回归，见讲义 2.2 节）。

表 3: world 任务：各层在相同 λ 下的“纬度 *MSE* + 经度 *MSE*”之和（注意这是两项 MSE 相加，不是 MSE），以及各层调参后的最好结果。

λ_2	第 11 层	第 23 层	第 35 层
0（不加正则）	789.17	683.36	664.11
0.01	545.20	612.48	660.90
0.05	**376.33**	510.73	648.67
0.1	**329.27**	472.08	634.64
0.5	**308.63**	452.67	556.20
1.0	**349.29**	471.72	502.26
各层最优 λ（纬/经）	**0.14 / 0.28**	0.2 / 0.28	2.0 / 2.0
各层最好“纬度 MSE + 经度 MSE”	**299.27**	447.98	449.13
（纬度 MSE / 经度 MSE）	(29.14/270.13)	(60.36/387.62)	(41.33/407.80)

原因分析

1. **在任何正则化水平下第 11 层都最好**（$\lambda_2 \geq 0.05$ 时明显领先），且各层调参后的“纬度 MSE + 经度 MSE”之差 299.27 vs 447.98/449.13，差距接近 50%，不是调参噪声。

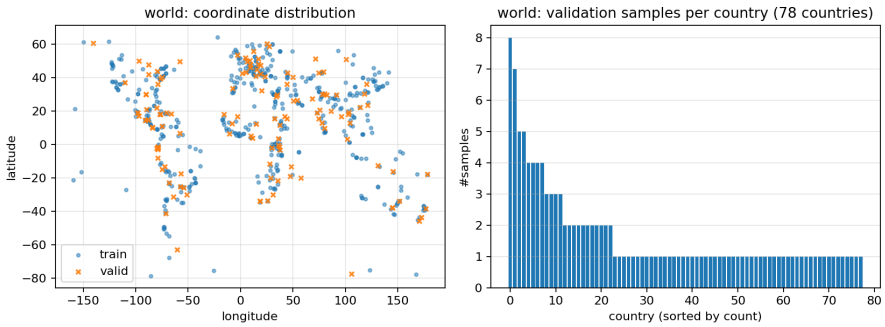


图 3: world 训练/验证集的分布对照（坐标分布、表征范数、常数/国家均值基线等）。

2. **深层表征的尺度与均值剧烈增长**：训练集表征范数为 42.1 ± 1.5（L11）、102.9 ± 6.3（L23）、824.7 ± 80.7（L35），特征均值向量范数 42.7/109.1/599.8。深层的输入尺度大得多，同一个 λ 在不同层含义完全不同（因此必须逐层选 λ），而它需要的强正则（第 35 层最优 $\lambda = 2.0$）本身就会损失信息。

3. 各层“单个特征与坐标的最大相关”其实接近：第 11/23/35 层纬度最大 $|r|$ 为 0.644/0.576/0.582，经度为 0.572/0.592/0.656，说明差距不来自某个超强单特征，而来自**多特征组合的泛化**：$N = 500 \ll D = 2560$ 时，深层更偏向训练集里出现过的国家/地点模式，在 130 条验证样本（含 19 个训练未见国家）上更容易过拟合——这一点在 $\lambda = 0$ 时最明显：第 11 层不加正则反而最差（789.17），说明它的可拟合（也即易过拟合）方向最多。

最终选层 按“每层独立调 λ 后比较验证集上纬度 *MSE* + 经度 *MSE*”的准则，**world 取第 11 层**，提交文件 `results/world.npz`。(各层该项指标分别为 299.27/447.98/449.13，对应的平均 MSE $\frac{1}{2}(\cdot)$ 分别为 149.64/223.99/224.57。)

1.5 思考题 5：最终模型如何选择正则化

1. **只用 ℓ_2（$\lambda_1 = 0$）**：本题目标是预测精度而非稀疏可解释性，且 ℓ_1 的次梯度在零点附近振荡（讲义也提示了这一点），对 $D = 2560$ 的探测回归没有必要引入额外的不稳定因素。

2. **粗网格 + 细网格两阶段**：粗网格取 $\lambda_2 \in \{0, 10^{-4}, 10^{-3}, 10^{-2}, 0.05, 0.1, 0.2, 0.5, 1\}$，找到最优点后在其两侧按 $\times\{0.5, 0.7, 1.4, 2\}$ 细化（world 第 11 层细网格实际落在 $0.07, 0.14, 0.28, 0.4$），避免对数间隔太粗而错过最优点。

3. **选择准则是验证集上的指标，不是训练 MSE**。选层选参时比较的是验证集上纬度 *MSE* + 经度 *MSE* 这个和（各层对应平均 MSE 只有一半）；不加正则时训练 MSE $\approx 5 \times 10^{-5}$（500 条、2560 维可完全拟合），验证集上“纬度 MSE + 经度 MSE”却高达 789，说明训练误差完全不可信。

4. **纬度、经度独立选 λ**：二者量纲虽同但难度差异极大（纬度 MSE 29、经度 MSE 270），独立选择后“纬度 MSE + 经度 MSE”为 299.27，优于共用一个 λ（$\lambda = 0.28$ 时为 300.46）。

5. **不追求单点最优，避免在 130 条验证集上过拟合**：第 11 层若纬、经共用一个 λ_2，则在 $\lambda_2 \in [0.14, 0.4]$ 内“纬度 MSE + 经度 MSE”为 $300.5 \sim 314.2$（相对波动 $< 5\%$），是一段平台而不是尖峰；最终取 $\lambda_{\text{lat}} = 0.14$、$\lambda_{\text{lon}} = 0.28$（“纬度 MSE + 经度 MSE” = 299.27）。验证集只有 130 条，单点最优很容易是噪声，平台内的取值差异对未公布的测试集几乎不会有影响。

1.6 思考题 6：验证集预测结果可视化

脚本 `plot_maps.py`。按推荐做法**不绘制任何国界线**，只画经纬度散点，并对经纬度坐标轴使用相同比例。

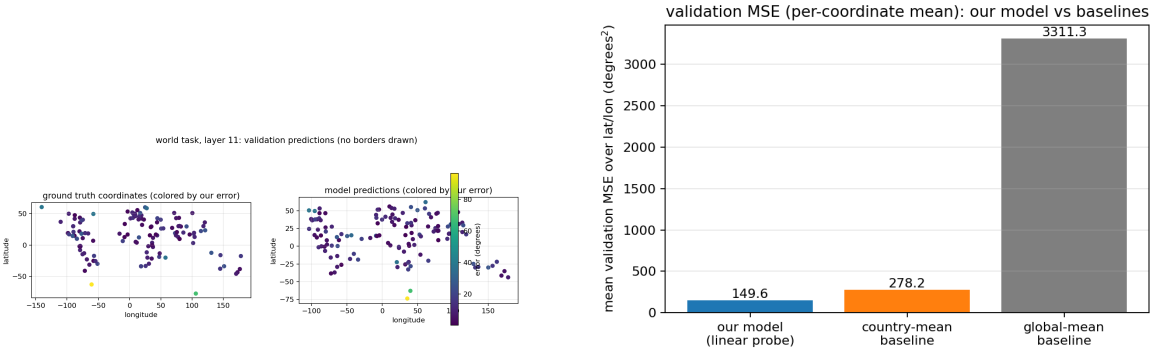


图 4: 左：130 条验证样本的预测坐标 vs 真实坐标（散点按误差着色）；右：我们的模型与两个基线的验证 MSE 对照（逐坐标平均 MSE）。

定量结果

- 我们模型在验证集上的总体 MSE 取两个坐标的逐坐标平均 MSE = 149.64；拆分看为纬度 MSE = 29.14、经度 MSE = 270.13 （两者之和 299.27 是“纬度 *MSE* + 经度 *MSE*”，不是 MSE）；按等距近似折算平均大圆距离误差约 1360 km。
- 对照（同样为逐坐标平均 MSE）：全局均值基线 3311.27，按训练集国家分组的均值基线 278.24。

1.7 思考题 7：是否能说明模型内部存在地理坐标表征，而不只是识别国家

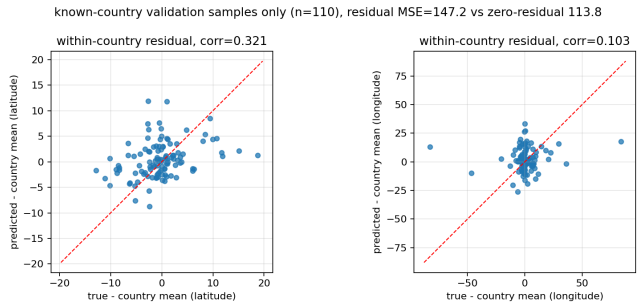


图 5: 扣除训练集国家均值后的残差对照，**仅在训练集中出现过的国家的 110 条验证样本上**评估：横轴为真实残差、纵轴为模型预测残差，红虚线为 $y = x$。若模型只“认国家”、不含国家内部坐标信息，散点应无相关且集中在 0 附近。

回答　证据是“部分支持、但不能单独成立”，需要与未见国家泛化合起来看。

1. **残差相关为正但明显偏弱**：把每条样本减去其所属国家在训练集中的平均坐标后，在训练集见过的 110 条上，模型预测残差与真实残差的相关系数为纬度 0.321、经度 0.104——存在同

表 4: 国家均值基线与本模型的分组对照（验证集 130 条；表中数值为逐坐标平均 MSE，即纬度、经度两维 MSE 的平均）。

分组	样本数	我们的模型	国家均值基线
全部验证样本	130	**149.64**	278.24（全局均值 3311.27）
训练集见过的国家	110	147.21	**113.77**
训练集未见的国家	20	**162.95**	1182.83（退化为全局均值）
残差分析：仅在训练集见过的国家（110 条）上			
残差预测误差 $\mathrm{mean}\left((\hat{r}-r)^2\right)$	110	147.21	113.77（r 恒为 0 的基线）
残差相关系数（纬 / 经）	110	0.321 / 0.104	—

向变化的信号，但远未接近 1，且经度方向已很弱。若模型只识别国家、完全不含国家内部信息，这两个相关应接近 0。

2. **但残差层面的误差并未优于“不预测”**：在同一 110 条上，模型残差预测误差 $\mathrm{mean}((\hat{r}-r)^2) = 147.21$，而“残差恒为 0”（完全不预测国家内部偏移）的基线 $\mathrm{mean}(r^2) = 113.77$。也就是说**模型给出的国家内部偏移反而使误差变大了**约 33.4（147.21 − 113.77），所以“能预测国家内部坐标”并不能从残差 MSE 上得到支持，只能从残差相关上看到微弱的线性信号。

3. **更强的证据来自未见国家泛化**：验证集中 20 条来自训练时未出现的国家，我们 MSE 162.95，而“按国家查表”的基线退化为全局均值（1182.83）。如果模型只会“认国家”，对未见国家就只能退化为常数预测、误差会很大；这里显著更优，说明表征里携带了可跨国家泛化的连续坐标信息。

4. **反面证据**：在训练见过的 110 条上，国家均值基线（113.77）仍优于我们（147.21），说明在见过的国家里“查国家均值”已是非常强的预测，模型并未在国家内部把误差进一步压下去。

5. 综合起来更审慎的表述是：**表征中既含国家级信息，也含可跨国家泛化的连续坐标信息**；后者主要由未见国家的泛化优势支持，而国家内部的残差证据（正相关）较弱、且残差 MSE 未超过零残差基线，不足以单独下结论。这与原文 Gurnee & Tegmark (2024) 关于“语言模型线性表示空间”的结论方向一致（线性探测可解码空间信息），但本实验的残差分析并不支持更强的“精确内部坐标”说法。

1.8 思考题 8：truth 训练/验证集的分布差异与应对

脚本 `data_analysis.py`（图 6）。

表 5: truth 训练集与验证集的差异（显著性检验用双样本 KS 检验）。

统计量	数值（训练集 5088 / 验证集 300）
正/负标签比例	0.5000 / 0.5000，两边均严格均衡
句长均值（字符）	60.95 vs 54.18（KS $p = 3.0 \times 10^{-7}$）
词数均值	10.32 vs 9.32（KS $p = 5.1 \times 10^{-5}$）
第 23 层表征范数	102.94 ± 6.30 vs 101.75 ± 6.63（KS $p = 0.028$）
逐维均值漂移（按逐维 std 归一）	0.128 / 0.121 / 0.136（第 11/23/35 层）
域分类器区分 train/valid 的测试准确率（第 23 层）	**0.9332**（0.5 表示不可区分）

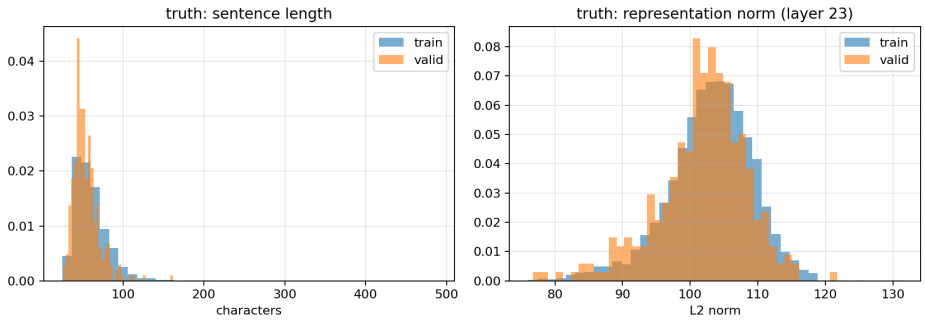


图 6: truth 训练/验证集分布对照：句长、表征范数与漂移、域分类器可分性。

差异 两类数据的**标签都是严格 50/50 均衡**，不存在标签偏移；差异主要在**输入（句长）与表征分布**：验证集句子显著更短，域分类器仅凭第 23 层表征就能以 93.3% 的准确率区分训练/验证样本，说明差异是线性可检出的、真实存在的。

应对

1. **正则化 + 早停**：λ_2 把训练准确率从 0.9988 压到 0.9381，验证准确率从 0.8567 提升到 0.8833，直接缩小泛化差距。
2. **按长度分桶定位差距来源**（最终模型，第 23 层）：验证集 < 55 字符准确率 0.857（$n = 182$）、55–65 字符 0.936（$n = 62$）、> 65 字符 0.911（$n = 56$）；训练集对应为 0.932/0.944/0.943。可见短句更难，而验证集里短句占比 61%（训练集 47%）——若按训练集句长分布重新加权，验证准确率约 0.894，即**约 1 个点的差距来自句长组成变化**，其余约 4 个点是真实泛化差距。这也解释了为什么总准确率（0.8833）看起来比训练准确率（0.9381）低很多。
3. **不做依赖句长的特征工程或增广**，避免把“长度”这一分布差异当作捷径学进权重里；预测只用第 23 层表征，不引入句长等表面特征。
4. **调参保守**：层数与 λ 虽然在验证集上选，但都选在平台区（$\lambda_2 \in [0.02, 0.05]$ 准确率均为 $0.877 \sim 0.883$）而非尖点，以降低在 300 条验证集上过拟合的风险；同时用 `sklearn` 独立复核（见思考题 3），确认该解就是同一目标函数的最优解，而非偶然的局部好点。
5. **如实承认**：仍有约 4 个点的真实泛化差距，且验证集小、被用于选层选参，存在一定的选择偏差；报告中的分桶结果可用于验收时解释。

1.9 思考题 9：truth 最终提交的选层与选正则

表 6: truth 任务：各层调参后的最好结果（粗网格 + 细网格，共 11 个 λ/层）。

层	最优 λ_2	验证准确率	训练准确率	$\lambda_2 = 0$ 时验证准确率
11	0.01	0.7533	0.8239	0.7067
23	**0.03**	**0.8833**	**0.9381**	0.8567
35	任意（0 即可）	0.8167	0.9809	0.8167

选层理由

1. 验证准确率上第 23 层（0.8833）显著优于第 11 层（0.7533）与第 35 层（0.8167），差距达 7–13 个百分点。
2. 从表征本身也能预测这一结果：第 23 层与标签相关性最强的特征 $|r|_{\max} = 0.376$、$|r| > 0.1$ 的特征有 1141 个，而第 11/35 层分别只有 180/572 个（$|r|_{\max} = 0.196/0.275$），即“真假”信息在第 23 层最线性可解码。
3. 第 35 层不加正则与加正则结果完全一样（都是 0.8167）且训练准确率 0.9809，说明它既没有更强的信号、又更容易过拟合。

选正则理由

1. 只用 ℓ_2，λ_2 粗网格 $\{0, 10^{-5}, 10^{-4}, 10^{-3}, 0.01, 0.1\}$ 后细网格 $\{0.005, 0.02, 0.03, 0.04, 0.05\}$；验证准确率随 λ_2 单调上升到平台：0.8567 ($\lambda = 0$) $\to$ 0.8633 (10^{-3}) $\to$ 0.8733 (0.005–0.01) $\to$ 0.8767 (0.02) $\to$ 0.8833 (0.03, 0.04, 0.05) $\to$ 0.8700 (0.1)。
2. 取平台中较早的 $\lambda_2 = 0.03$（平台 $[0.02, 0.05]$ 内三点同为 0.8833，取值不敏感），对应训练准确率从 0.9988 降到 0.9381，说明确实抑制了过拟合而非单纯拟合验证集。
3. 用 `sklearn` 交叉验证换算 $C = 1/(2N\lambda_2) = 0.00328$，得到同样的 0.8833、$\cos(w) = 0.999999$，说明该 λ 对应的是目标函数的全局最优，不是手写 GD 的偶然结果。
4. 因为验证集只有 300 条，λ 取平台内部而非边缘，并保留 ℓ_2 而非 ℓ_1（任务是分类预测，稀疏性无收益）。
5. 训练配置本身也是一种“隐式正则”，单独考察过：动量 0.99/8000 步、普通 GD 20000 步（含不同 patience）、普通 GD + 学习率衰减，$\times\ \lambda_2 \in \{0, 0.01, 0.03, 0.05\}$ 共 16 组。普通 GD 收敛慢（2 万步仍欠收敛，训练准确率仅 0.9312）相当于隐式早停，在官方验证集上 $\lambda_2 = 0$ 可到 0.8867，但只比 0.8833 多 1 条样本。为避免在 300 条验证集上反复择优，把训练集内部再切 10% 复核（4580/508，固定随机种子）：内部验证集上本配置最好（0.9016），普通 GD 的 $\lambda_2 = 0/0.01/0.03$ 分别为 0.8976/0.8976/0.8957，故最终仍提交“动量 0.99 + $\lambda_2 = 0.03$”。

提交物

- `results/world.npz`：`weights` 形状 $(2, 2560)$、`bias` 形状 $(2,)$，类型 `float64`；层数 **11**。
- `results/truth.npz`：`weights` 形状 $(2560,)$、`bias` 形状 $()$，`float64`；层数 **23**。

A 复现方式与代码位置

核心代码位置（未使用 `sklearn` 的拟合接口完成训练）：

- `model.py`：线性回归 / 逻辑回归的全批量梯度下降（ℓ_1 次梯度、ℓ_2 正则、幂迭代自动学习率、可选动量与学习率衰减、基于损失的早停），对应讲义 2.1 节全部公式；偏置不参与正则。
- `train1.py` / `train23.py`：助教框架下的训练入口。
- `sweep.py`：world/truth 的层数与 λ 粗细网格搜索，并写出 `results/*.npz`。
- `coef_path.py`、`feature_selection_demo.py`、`compare_sklearn.py`：思考题 1–3。
- `data_analysis.py`、`plot_maps.py`：思考题 6–8 的分析与可视化。

复现命令（在 `LABs/LAB1` 下）：

```
python train1.py
python sweep.py                    # 粗+细网格，产出 results/*.npz
python coef_path.py                # 图 1
python feature_selection_demo.py   # 图 2
python compare_sklearn.py          # 表 3
python data_analysis.py            # 图 3（分布差异）
python plot_maps.py                # 图 4--6（地图可视化与基线）
```

B 主要实验记录

表 7: world：第 11 层 λ_2 与验证集指标（细网格标注为 “细”）。“纬度 MSE + 经度 MSE” 列为两项 MSE 之和，不是 MSE。

λ_2	纬度 MSE	经度 MSE	纬度 MSE + 经度 MSE	阶段
0	75.643	713.531	789.17	粗
0.001	68.582	670.110	738.69	粗
0.01	44.491	500.711	545.20	粗
0.05	31.188	345.138	376.33	粗
0.07	29.998	320.862	350.86	细
0.1	29.296	299.970	329.27	粗
0.14	**29.141**	285.099	314.24	细
0.2	29.497	274.676	304.17	粗
0.28	30.329	**270.130**	300.46	细
0.4	31.785	271.348	303.13	细
0.5	33.047	275.587	308.63	粗
1	39.411	309.883	349.29	粗
最终取纬度 $\lambda = 0.14$、经度 $\lambda = 0.28$，“纬度 MSE + 经度 MSE” = **299.27**				

表 8: truth：第 23 层 λ_2 与准确率。

λ_2	训练准确率	验证准确率
0	0.9988	0.8567
0.001	0.9963	0.8633
0.005	0.9752	0.8733
0.01	0.9619	0.8733
0.02	0.9465	0.8767
0.03	0.9381	**0.8833**
0.04	0.9306	0.8833
0.05	0.9261	0.8833
0.1	0.9121	0.8700

训练配置补充实验 原始记录见 `results/opt_sweep.txt`、`results/tiebreak.txt`。truth 上比较 4 种配置（动量 0.99/8000 步、普通 GD 20000 步 patience 50/200、普通 GD+ 学习率衰减）× $\lambda_2 \in \{0, 0.01, 0.03, 0.05\}$；world 第 11 层上比较 3 种配置 × $\lambda_2 \in \{0.14, 0.2, 0.28, 0.4\}$。world 结果：同一 λ 下三种配置的“纬度 MSE + 经度 MSE”相差不到 1%（如 $\lambda = 0.28$：300.46 / 300.45 / 300.15），且都劣于“纬度、经度各自取 λ”的 299.27，故不更换配置。truth 结果与内部切分复核见思考题 9 第 4 点。

C 实现过程中的问题与解决

1. **闭式解核对差一个 2 倍**：一度用 $(X^\top X/N + 2\lambda_2 I)^{-1}$ 当参考解，与 GD 结果总差 3×10^{-2}。按讲义目标 $\mathrm{mean}(r^2) + \lambda_2\|w\|^2$ 重新求导应为 $(X^\top X/N + \lambda_2 I)$，改用 1× 后偏差降到 10^{-16}，说明 `model.py` 实现正确、参考解写错了。

2. **次梯度无法得到精确 0**：固定步长的次梯度法在零点附近振荡，λ 很大时损失仍停在 2.3（最优 1.0）。系数路径与稀疏案例改用 ISTA 得到精确稀疏解，`model.py` 保持次梯度（符合讲义要求）。

3. **`sklearn` 接口**：`LinearRegression` 没有 `alpha`，岭回归应使用 `Ridge`；二分类的 `coef_ shape` 是 $(1, D)$，需 `ravel()` 后再比较。

4. **全批量 GD 在原始特征上收敛慢**：$N = 500 \ll D = 2560$ 且特征均值非零时存在近零曲率方向，60 万步仍有 0.14 的目标差；标准化后同一 GD 收敛到与 `sklearn` 完全一致的解（10^{-14}）。

D 实验反馈与建议

- 文档对 world 任务提示“测试集分布更接近验证集”，但未说明验证集有多少条；建议补充验证集/测试集规模，便于判断 λ 网格搜索的可信区间。
- 建议提供一个官方的评估脚本或基线数值（如全局均值、国家均值），方便同学自查；本次的国家均值基线是自己实现的，与文档描述的“按训练集国家分组的平均坐标基线”一致。

- 附录 B 的算力平台教程对非计算机专业同学门槛略高，建议给出可直接运行的 `sbatch` 模板与常见报错示例。